엘라스틱서치를 활용하여 고급 검색엔진 만들기

Henry Lee

Overview

- 검색 엔진 기술의 개요
- 엘라스틱서치를 사용하여 간단한 쇼핑몰 검색 기능을 만들기 [실습 위주]
- 지식그래프의 개요 [실습 포함]
- 이미지 처리를 활용하여 검색 결과를 향상 시키기 [실습 위주]
- 검색 랭킹 [실습 포함]

Prerequisites

기본지식

- 파이썬 (Python), 자바스크립트 (JavaScript), PHP, HTML 사용가능
- 호스트, 포트, 서비스 등 네트워킹 관련 기본지식 및 서버 개발에 대한 기본 이해지식
- RESTful 아키텍처에 대한 이해
- Docker 에 대한 기본 지식

사용되는 도구

- 윈도우나 맥, 또는 리눅스 처럼 Docker 가 지원되는 운영체제 (맥과 윈도우 예제 설치 설명은 첨부됨)
- Apache, WordPress, Elasticsearch, Kibana, 인터넷 브라우저, TensorFlow, MySQL, Docker
- Optional: Postman, MySQL Workbench, Microsoft Visual Studio Code

What you will learn

- 검색 기술에 대한 기본 지식
- 엘라스틱서치를 활용한 검색 시스템 구축
- 지식 그래프, 부속 처리 기술들을 사용한 고급 검색 기술 활용법
- 검색 랭킹의 기본 지식, 검색 결과의 개인화에 대한 개요
- 예제를 통해 위 기술들에 대한 기본적인 실습

Why You Should Take This Course

- 빅데이터의 경쟁력은 데이터를 최대한 빠르고 효율적으로 정리해 주는 기술들이다.
- 현존하는 데이터의 규모는 현재도 폭발적인 성장을 하고 있다.
- 빅데이터를 다룰 줄 아는 자가 빅데이터의 파라다임을 이끄는 기업의 핵심 전문가가 된다

About Myself

- 1980년대 때부터 개발 경험 시작
- 대략 20년 전부터 시작된 엔지니어 실무 경력
- 대략 15년 전부터 검색 엔진 기술 개발
- 실리콘밸리 FAANG 기업들에서 검색 엔진 엔지니어로 10년 정도 근무
- 대략 3년정도 실리콘밸리의 창업 경험

1.검색 엔진 기술의 개요

Overview

- 검색 엔진 기술이란?
- SQL, NoSQL 과의 비교
- 검색 엔진 기술의 기본 아키텍쳐
- 실리콘밸리에 검색 기술 활용 사례

검색 엔진 시스템이란?

컴퓨터 시스템에 저장된 정보를 찾아주는 것을 도와주도록 설계된 정보 검색 시스템

[출저: <u>위키피디아</u>]

검색 시스템들의 사례

- 오프라인
 - 파일 검색, 데스크탑 검색 (마이크로소프트 코타나)
- 검색 서비스
 - 웹 검색, 이미지 검색, 비디오, 오디오 검색 등등
- 인터페이스형
 - 인공지능 개인비서: 아마존 알렉사, 삼성 빅스비 등
 - 지도형: 카카오맵, 배달앱 등
- 추론형
 - O 부동산: Zillow, Redfin
 - O Inference-as-a-service: 팔란티어, 케임브리지 애널리티카

SQL로는 안되나요?

Scale, Speed, and Usefulness

SQL vs 검색엔진

SQL

- ACIDic, even in read replica
- Slows down as data size increases O(Log n)
- Realtime up-to-date data
- Advanced search features / ranking very difficult
- Linear increase in traffic can cause exponential decay in service speed

검색엔진

- Queries returned in near constant time
 ~O(1)
- Data can expand almost infinitely
- Data can be stale
- Traffic increase is unrelated to the system itself, serving systems can grow linearly with the traffic

검색 엔진 시스템이 대체 무엇인가요?

검색엔진 = Index

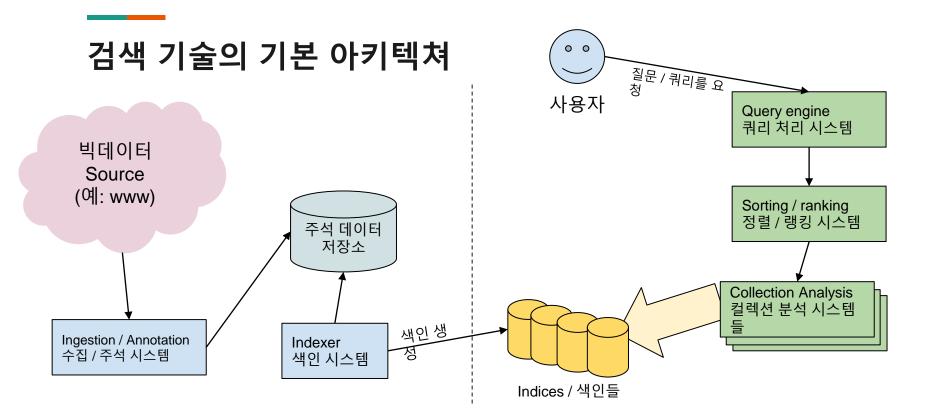
1655 년 출판된 Atlas Maior의 색인 [출처: <u>위키피디아</u>]

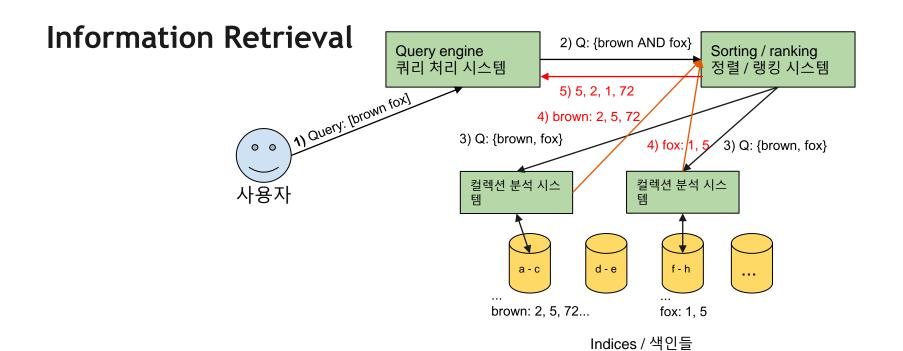


Index (색인) 란

A		50
Aaron	51	
About	52	
В		32,50
Baby		12
Bit		23,50,77
Bitten	30,23	
Bitter	55	
• • •		

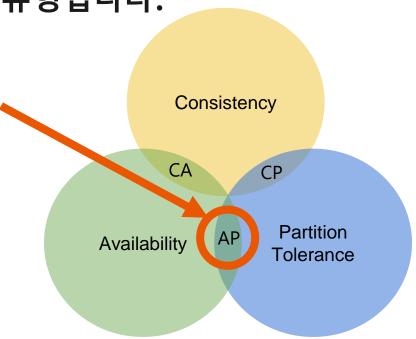






NoSQL DB들과 어떻게 다른가요?

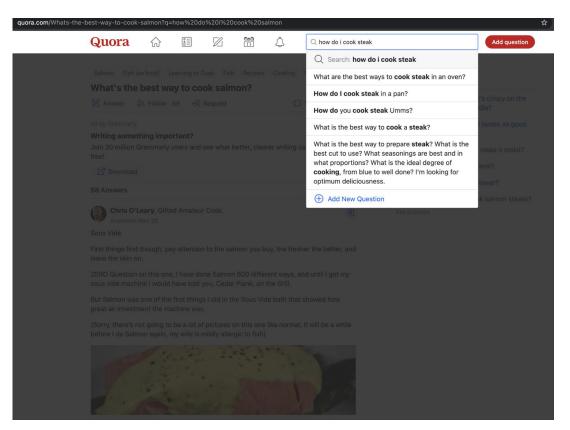
검색엔진은 전문화된 NoSQL의 유형입니다.



검색 엔진 기술의 활용사례

Quora

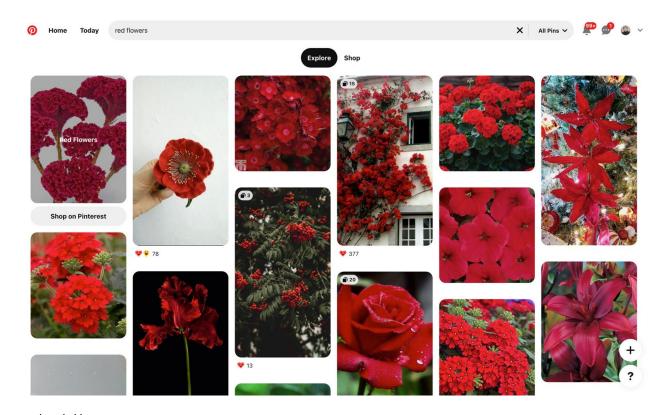
자연어 / 관련 검 색



자료출처: [www.pinterest.com]

Pinterest

이미지 검색



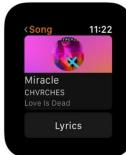
자료출처: [www.pinterest.com]

Soundhound

음원 검색









자료출처: [play.google.com, apps.apple.com]

Palantir

Data Insights

n/a

V23andMe HOME ANCESTRY HEALTH & TRAITS RESEARCH FAMILY & FRIENDS Upgrade Q C List Family Tree Map Frequently Asked Questions

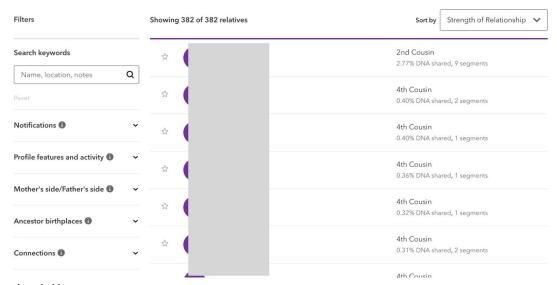
Edit profile

23andMe

DNA 검색

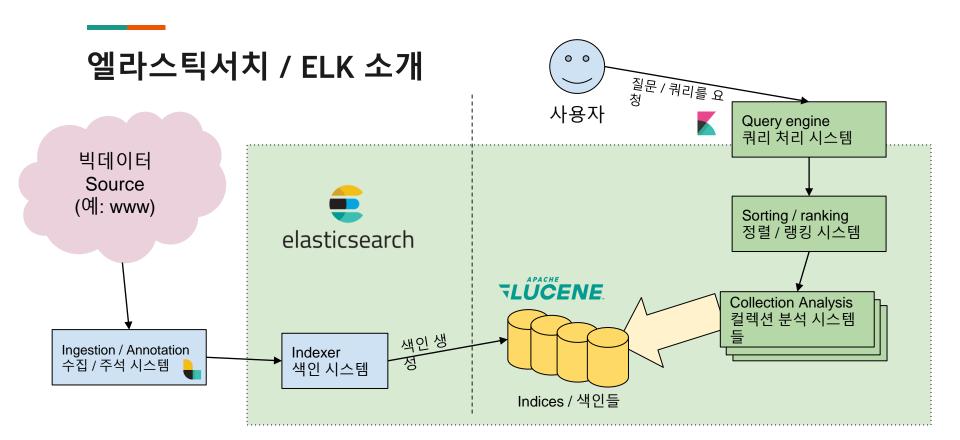
DNA Relatives

Get started with your predicted relationships, then connect and message to learn more.



자료출처: [23andme.com]

2. 엘라스틱서치를 사용하여 검색 기능을 추가하기



결제 내계정 상점 장바구니 홈페이지

Login/Register



플라워몰 예저

· 홍/상점 **상점**

http://localhost:
8000/

검색 ...

최신 글

안녕하세요!

최신 댓글

안녕하세요!**의** 워드프레스 댓글 작성자

보관함

2021년 7월

카테고리

□ INSE

7개 결과 출력







대형 테라코타 화분 60,000₩ **30,000₩**



데이지 꽃 세트 12,000₩



기본순

민들레 및 여러가지 꽃과 화병 65,000₩ 40,000₩







플라워몰 실행하기

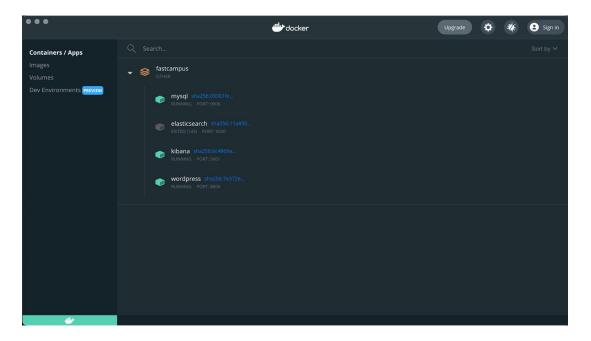
Download and install Docker at:

https://www.docker.com/products/docker-desktop

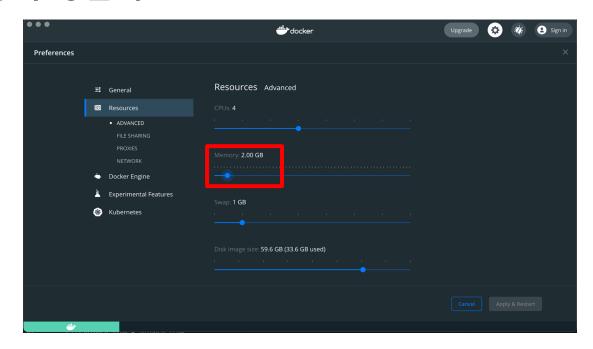
Then run

> docker compose up -d

엘라스틱서치가 실행이 않될때



엘라스틱서치가 실행이 않될때



플라워몰 웹사이트

http://localhost:8000/

플라워몰에 검색 기능 추가하기

```
색인 프로그램 /indexer/ingestor1.py
 1. > cd ingestor
 2. Install Python3 [Mac, Windows]
    https://www.python.org/downloads/
 3. pip3 install mysql-connector
    pip3 install requests
 4. > python3 tools/create index1.py
    (https://www.elastic.co/guide/en/elasticsearch/reference/current/docs-
    index .html)
 5. > Python3 ingestor1.py
     (https://www.elastic.co/guide/en/elasticsearch/reference/current/docs-
    index .html)
```

엘라스틱서치의 인덱스 확인

엘라스틱서치에서 검색하기

http://localhost:9200/products/_search?q=장미

플라워몰 웹사이트에 엘라스틱서치 검색을 연결하기

```
1) 쇼핑몰: http://localhost:8000/
```

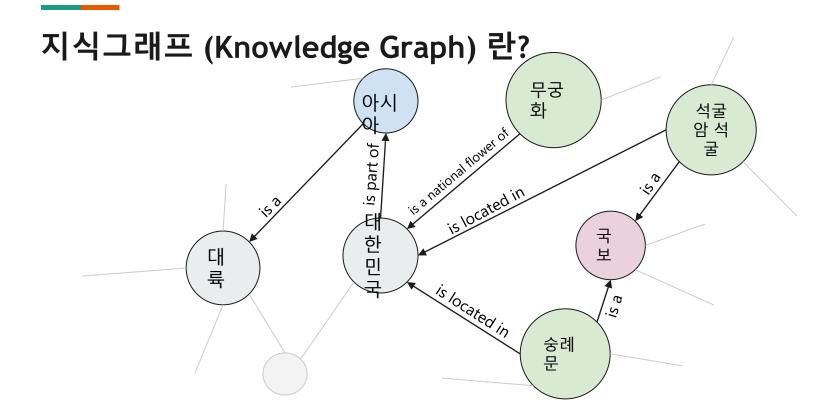
2) 검색 페이지 추가: www/search.php

검색 연결하기

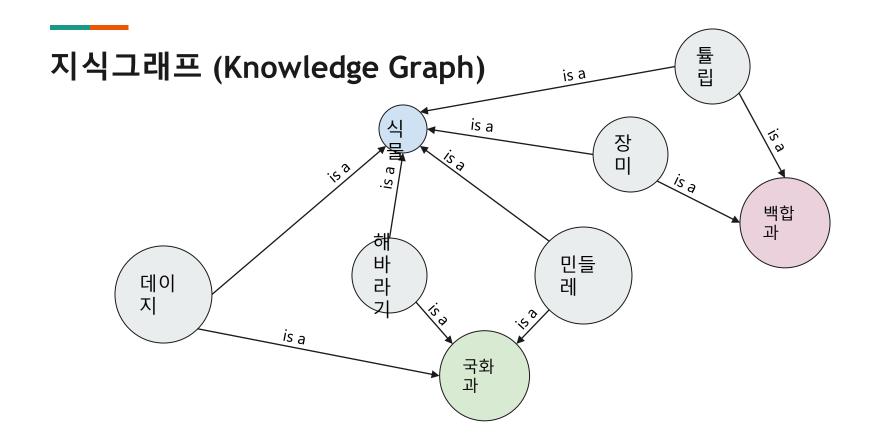
www/wpincludes/general
template.php:322
-335

```
docker-compose.yaml
                                         m general-template.php ×
                        search.php
$form = ob_get_clean();
           } else {
              // Build a string containing an aria-label to use for the search form.
               if ( $args['aria label'] ) {
                  $aria_label = 'aria-label="' . esc_attr( $args['aria_label'] ) . '" ';
               } else {
                   * If there's no custom aria-label, we can set a default here. At the
                   * moment it's empty as there's uncertainty about what the default should be.
                  $aria label = '':
               if ( 'html5' === $format ) {
                  esc url( home url( '/search.php' ) ) . '">
                      <label>
                          <span class="screen-reader-text">' . _x( 'Search for:', 'label' ) . '</span>
                          <input type="search" class="search-field" placeholder="' . esc attr x( 'Search &hellip;</pre>
                          ', 'placeholder' ) . '" value="' . get_search_query() . '" name="s" />
                      </label>
                      <input type="submit" class="search-submit" value="' . esc_attr_x( 'Search', 'submit")</pre>
                      button') . '" />
                  </form>':
               } else {
                  $form = '<form role="search" ' . $aria label . 'method="get" id="searchform"</pre>
                  class="searchform" action="' . esc_url( home_ur ( '/search.php'
                          <label class="screen-reader-text" for="s">' . _x( 'Search for:', 'label' ) . '</label>
                          <input type="text" value="' . get_search_query() . '" name="s" id="s" />
                          <input type="submit" id="searchsubmit" value="' . esc_attr_x( 'Search', 'submit</pre>
                          button') . "" />
                      </div>
                  </form>';
```

3. 지식그래프 (Knowledge Graph) 를 활용하여 검색품질을 향상하기



지식그래프 (Knowledge Graph) 란? 원숭 이 비행 기 사과 빠름 맛있 음 빨 강 길 음 길이 바나



지식그래프의 활용사

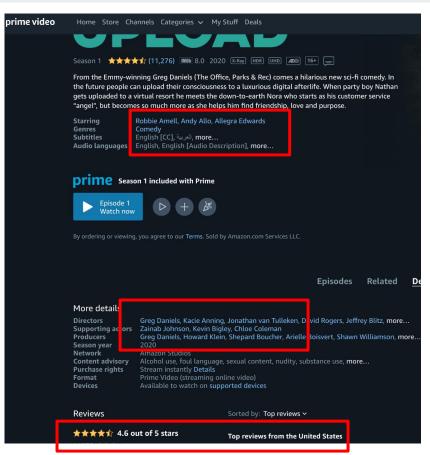
스마트 스피커

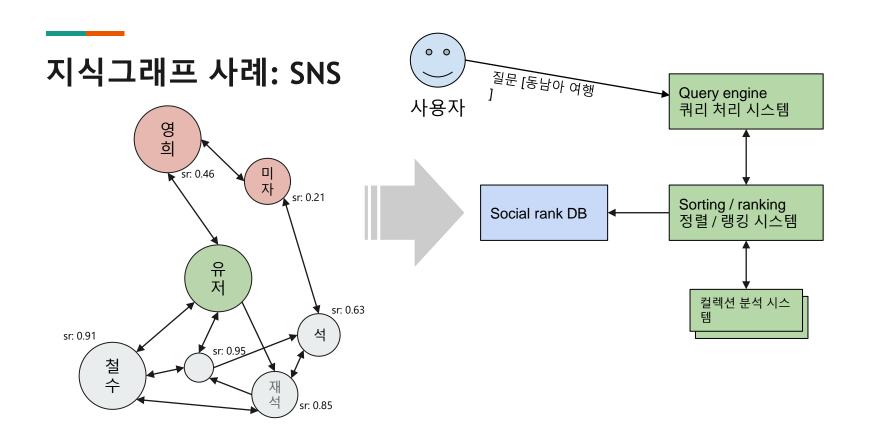


출처: <u>위키피디아</u>

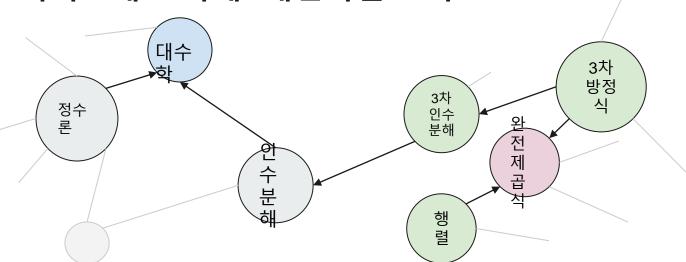
지식그래프의 활용사례

- SNS
- 개인화된 교육
- 날씨 예측
- 선거 공략
- 교통 정책
- 정부 오픈 데이터
- 반테러/보안
- 엔터테인먼트
- 금융





지식그래프 사례: 개인화된 교육



한글 위키미디아 데이터덤프

https://dumps.wikimedia.org/kowiki/

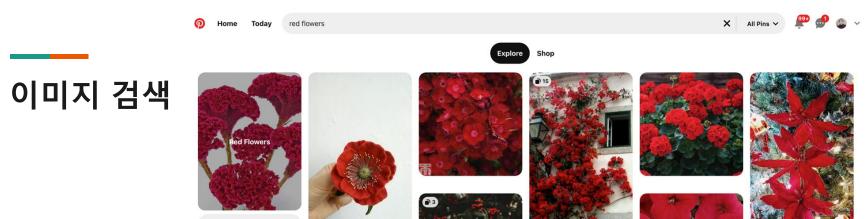
실습: 위키미디아 데이터를 사용하여 관련 키워드 확장하기

- > create_index2.py
- > ingestor2.py

실습: 위키미디아 데이터로 문서의 속성을 키우기

> ingestor2.py

4. 검색 부속 처리 사례: 이미지 검색



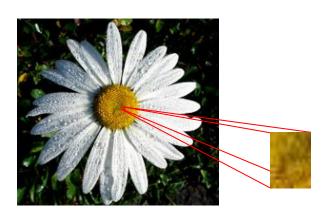
Shop on Pinterest **9 3** 78 **9** 377

출처: <u>핀터레스트</u>

이미지 검색 활용도

- 유사 이미지 검색
- 이미지 / 동영상 저작권 검색
- 유사한 제품 검색
- 시장 조사 (티비 시청률 / SNS 인지도)
- 메타데이터 추론 및 추출

이미지 검색 사례: 유사 이미지 검색



이미지출처 [www.flickr.com]



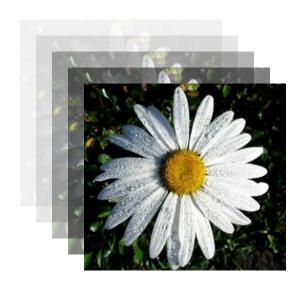
이미지 검색 사례: 유사 이미지 검색



이미지출처 [www.flickr.com]



이미지 검색 사례: 동영상 저작권 검색



Snapshot [Per color channel]

실습: 이미지 색상 검색

> ingestor3.py

실습: 간단한 이미지 Classification 실습

> pip3 install -q tf-nightly

5. 검색 랭킹

Ranking and Relevance

- Showing results that are more relevant first
- Ranking and relevance is usually marked in numeric values
- The numeric values usually comprises of many factors, combined into a single number

Ranking and Relevance

17ms 안에 3개의 검색결과를 찾았습니다.



튤립 부커 (score:0.98423386) 주문시 2. 2의 전드의 배속 시간이 필요합니다. 국내배송.





<u>상미 부개 (score:0.8571708)</u> 세서 배송 <mark>무는 한 및 강리의 부개</mark>입니다.

재검색 하기

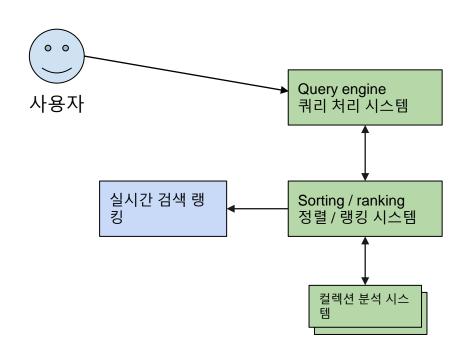
검색

Finding user's intent

- For a query [데이지]
- Do they want to know about the flower?
- Do they want a text containing the word?
- Do they want recent news on the flower?
- Should a document with frequency of the query word be ranked higher?

Ask the user for intent

- 실시간 검색
- 통합 검색



Ranking: TF/IDF

TF: Term-frequency 단어 빈도 특정한 단어가 문서 내에 얼마나 자주 등장하는지를 나타내는 값

tf = sqrt(termFreq)

IDF: Inverse document frequency 역문서 빈도 한 단어가 문서 집합 전체에서 얼마나 공통적으로 나타나는지를 나타내는 값

idf = 1 + ln(maxDocs/(docFreq + 1))

실습: Local-boost

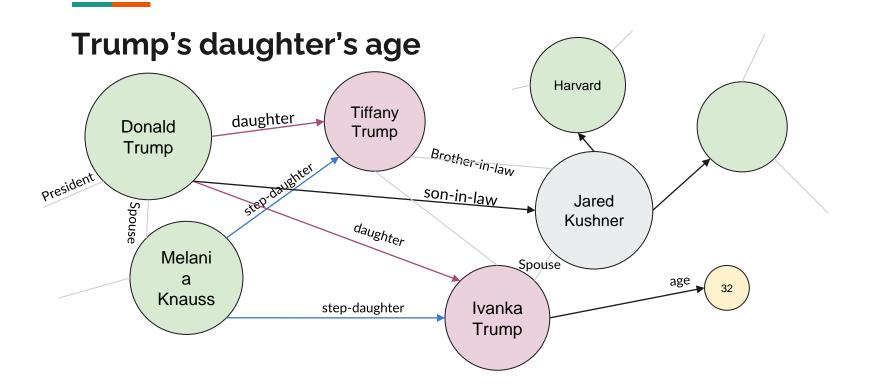
> ingestor4.py

실습: Demotion / Promotion (by color)

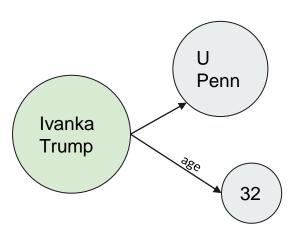
```
> create_index3.py
```

- > ingestor4.py
- > search2.php

Knowledge graph: Handling complex queries



Ivanka Trump's Age



{q: "Ivanka Trump's Age"} Ivanka Trump's Age Query engine 사용자 [a: "Ivanka Trump's Age"] 쿼리 처리 시스템 [entity: "¡vanka trump", tenuty: wanka trump, tentity:
confidence: 0.93, fentity:
confidence: confidence:
"trump", "age", confidence:
fentity: "age", confidence: U Penn Ivanka KG Index Sorting / ranking 지식 그래프 인덱스 Trump 0.43... 정렬/랭킹시스템 ₹e 32 KG 컬렉션 분석 시스

